Prédiction de la résistance à la ciprofloxacine chez *Escherichia coli*

Démarche méthodologique, protocole expérimental et justification des choix en Machine Learning et Deep Learning

Benjamin HIN
Alexandre Aïtoun
Baptiste Jacquet
Projet Machine Learning & Deep Learning

25 octobre 2026

Résumé

Ce rapport décrit la démarche méthodologique retenue pour construire un modèle de prédiction de la résistance à la ciprofloxacine chez *Escherichia coli* à partir de données génotypiques. Le jeu de données initial contient 5 935 isolats et 20 731 variables de présence/absence issues d'un pangénome. Comme les gènes du *Quinolone Resistance-Determining Region* (QRDR) sont présents chez toutes les souches et ont été filtrés comme invariants, nous enrichissons la matrice avec 198 polymorphismes nucléotidiques simples (SNP) non synonymes dans les gènes cibles et régulateurs de la résistance. Nous justifions ensuite un découpage train/validation/test *groupé par MLST*, afin d'éviter la fuite de clones, puis nous comparons des modèles linéaires, des ensembles d'arbres et des réseaux de neurones. Le protocole privilégie des métriques adaptées au déséquilibre des classes (PR-AUC, rappel des résistants, F1, balanced accuracy, calibration) plutôt que l'exactitude brute. La démarche inclut aussi une LogReg avec interactions QRDR, des MLP (SNP, top-k, complet), un autoencodeur suivi d'un classifieur (équivalent d'un *phenotype encoder*), TreeSHAP/LIME, et une analyse des erreurs par lignage. Les approches hors périmètre (CNN, modèles de fondation) sont justifiées en annexe. L'objectif n'est pas de démontrer que le Deep Learning est supérieur, mais de mener une comparaison contrôlée, interprétable et reproductible.

Mots-clés : résistance aux antimicrobiens, *Escherichia coli*, ciprofloxacine, QRDR, apprentissage supervisé, Deep Learning, PR-AUC, fuite de données, interprétabilité.

Table des matières

1 Contexte, problématique et objectifs **4**
1.1 Un enjeu de santé publique 4
1.2 Pourquoi un modèle prédictif ? 4
1.3 Questions de recherche 4
1.4 Contributions attendues 5
1.5 Positionnement par rapport à l'étude associée 5

2 Données et enrichissement **7**
2.1 Jeu de données initial . . . 7
2.2 Le problème des gènes core et l'absence des mutations QRDR . . . 8
2.3 Extraction ciblée des SNP QRDR et régulateurs . . . 8
2.4 Structure finale de la matrice . . . 9

3 Partitionnement et prévention de la fuite de données **10**
3.1 Le piège du découpage aléatoire . . . 10
3.2 Découpage groupé par MLST . . . 10
3.3 Tailles et composition des splits . . . 10
3.4 Pourquoi trois ensembles ? . . . 11

4 Démarche en Machine Learning **11**
4.1 Formalisation du problème . . . 11
4.2 Régression logistique . . . 11
4.3 Régression logistique avec interactions QRDR . . . 12
4.4 Forêt aléatoire . . . 12
4.5 XGBoost . . . 13
4.6 Jeux de caractéristiques et ablations . . . 13
4.7 Gestion du déséquilibre . . . 14

5 Démarche en Deep Learning **14**
5.1 Un MLP est-il pertinent ? . . . 14
5.2 Architecture et entraînement . . . 14
5.3 Autoencodeur : apprentissage de représentation (*phenotype encoder*) . . . 15
5.4 Interprétabilité de l'autoencodeur . . . 15

6 Protocole d'évaluation **16**
6.1 Matrice de confusion et métriques . . . 16
6.2 Pourquoi l'exactitude seule est trompeuse . . . 17
6.3 Choix du seuil . . . 17
6.4 Incertitude et variabilité . . . 18
6.5 Analyse des erreurs et des sous-groupes . . . 18
6.6 Diagnostic du sur-apprentissage . . . 18

7 Interprétabilité et validation biologique **18**
7.1 Pourquoi interpréter ? . . . 18
7.2 Quand interpréter dans la démarche ? . . . 19
7.3 Outils selon les modèles . . . 19
7.4 SHAP : ce que cela permet . . . 19
7.5 LIME : rôle complémentaire . . . 20
7.6 Précautions . . . 20
7.7 Validation biologique attendue . . . 21

8 Plan expérimental **21**
8.1 Phases du projet . . . 21
8.2 Matrice des expériences . . . 22
8.3 Reproductibilité . . . 22
8.4 Extensions au-delà du cœur de la démarche . . . 22

9 Résultats préliminaires et lecture critique **23**
9.1 Modèles complets . . . 23
9.2 Comparaison des représentations . . . 23
9.3 Lecture des résultats . . . 23
9.4 Interprétation préliminaire . . . 24

10 Limites **24**
10.1 Limites méthodologiques . . . 24
10.2 Limites du Deep Learning . . . 25

11 Conclusion **25**

A Approches non retenues dans la démarche **28**
A.1 CNN sur la matrice tabulaire . . . 28
A.2 Modèles de fondation génomiques . . . 28
A.3 Apprentissage multi-tâches comme expérience principale . . . 28
A.4 Synthèse . . . 29

B Reproductibilité : commandes et fichiers **29**
B.1 Fichiers principaux . . . 29
B.2 Commandes . . . 29
B.3 Chargement des données . . . 30

C Glossaire **30**

D Notations **33**

1 Contexte, problématique et objectifs

1.1 Un enjeu de santé publique

La résistance aux antimicrobiens (AMR) est l'une des principales menaces sanitaires mondiales. Les infections causées par des bactéries résistantes entraînent une mortalité importante et compliquent les décisions thérapeutiques (Murray et al., 2022). *Escherichia coli* est un pathogène majeur, responsable d'infections urinaires, digestives et systémiques, et la ciprofloxacine, une fluoroquinolone à large spectre, fait partie des antibiotiques dont l'efficacité est directement menacée par l'émergence de résistances (Hooper & Jacoby, 2016).

Chez *E. coli*, la résistance aux fluoroquinolones repose en grande partie sur des mutations ponctuelles dans la *Quinolone Resistance-Determining Region* (QRDR) de l'ADN gyrase (`gyrA`, `gyrB`) et de la topoisomérase IV (`parC`, `parE`), ainsi que sur des altérations de régulateurs comme `marR`, `acrR` ou `soxR` (Aldred et al., 2014). La détection rapide de ces mécanismes à partir du génome est donc un enjeu à la fois clinique et épidémiologique.

1.2 Pourquoi un modèle prédictif ?

Un modèle entraîné sur des génomes et des phénotypes peut aider à :

— prioriser les tests phénotypiques ;

— détecter des mécanismes de résistance connus ou émergents ;

— comprendre quelles mutations portent le signal prédictif ;

— évaluer la robustesse des modèles sur des lignages non vus.

Cependant, un modèle prédictif n'a de valeur que si son évaluation est honnête. Trois pièges doivent être évités :

1. **la fuite de données** : des clones ou des lignages proches se retrouvent à la fois dans l'entraînement et dans le test ;
2. **le déséquilibre des classes** : les souches sensibles sont majoritaires, ce qui favorise des modèles qui prédisent presque toujours « sensible » ;
3. **le sur-apprentissage** : un modèle peut mémoriser l'ensemble d'entraînement et échouer sur des données nouvelles.

1.3 Questions de recherche

Le projet est structuré autour de cinq questions :

Questions de recherche

1. Peut-on prédire le phénotype sensible/résistant à partir du génotype avec une performance utile ?
2. Quelle représentation est suffisante : les 198 SNP QRDR, le pangénome complet, ou les deux ?
3. Les modèles complexes (forêts, boosting, réseaux de neurones) apportent-ils un gain réel par rapport à une régression logistique ?
4. Quel est l'effet d'un découpage groupé par MLST sur l'estimation de la généralisation ?
5. Le Deep Learning est-il pertinent pour ce type de données tabulaires, et à quelles conditions ?

1.4 Contributions attendues

Le projet ne se limite pas à comparer des scores. Il vise à produire :

— un jeu de données enrichi et documenté, séparé du jeu de base pour préserver la comparabilité ;

— un découpage train/validation/test groupé par MLST, reproductible ;

— un benchmark de modèles classiques et neuronaux sur les mêmes données ;

— une analyse du sur-apprentissage et de la fuite de données ;

— une interprétation biologique des variables les plus importantes ;

— une discussion critique sur l'usage du Deep Learning en génomique tabulaire.

1.5 Positionnement par rapport à l'étude associée

Le jeu de données est associé à deux publications complémentaires, qu'il faut distinguer pour éviter les confusions.

1. L'étude de construction du jeu de données (2024). Mets et Morin (Mets & Morin, 2024) construisent et valident la ressource : pangénome de référence, appel de variants, annotation des variants non synonymes, statistiques descriptives et tests hypergéométriques sur des gènes AMR connus. Cette étude **ne réalise pas d'apprentissage supervisé** au sens du Machine Learning : elle ne compare ni régression logistique, ni forêt aléatoire, ni XGBoost, ni réseau de neurones. Le jeu de données est explicitement présenté comme un *testbed* pour de futurs modèles de prédiction génotype–phénotype. Les perspectives annoncées incluent l'utilisation d'un *phenotype encoder*, l'étude des interactions gène–gène et la prédiction de phénotypes.

2. L'étude de prédiction génomique (2025). Patton, York et Sandler (Patton et al., 2025) utilisent ce jeu de données pour caractériser l'architecture génétique de trois phénotypes AMR, dont la ciprofloxacine. Leur méthode principale est un **modèle linéaire mixte bayésien parcimonieux** (BSLMM) implémenté dans GEMMA (Zhou et al., 2013), avec une version probit, une matrice de *relatedness* centrée, 326 625 marqueurs (MAC $\geq$ 250) et 32 441 marqueurs de présence/absence. Ils complètent l'analyse par :

— une régression logistique avec termes d'interaction deux à deux pour tester l'épistasie entre les trois mutations majeures de la ciprofloxacine ;

— un modèle de Markov caché (corHMM) pour inférer l'ordre d'apparition des mutations le long de l'arbre phylogénétique ;

— une PCA et une régression logistique multinomiale pour relier la structure génomique au pays, à l'année et au MLST ;

— des analyses phylogénétiques (IQ-TREE) et de déséquilibre de liaison (PLINK).

Dans les méthodes décrites, il n'y a pas de forêt aléatoire, de XGBoost, de SVM, de MLP, de CNN ni de modèle de fondation. Leur « prédiction génomique » estime des effets de marqueurs et l'héritabilité ; les méthodes décrites ne rapportent pas de split train/validation/test avec PR-AUC, rappel et matrice de confusion. Les modèles non linéaires (autoencodeurs, transformers, graphes de neurones) sont explicitement présentés comme une **perspective future**, pas comme une expérience réalisée.

Table 1 – Positionnement du projet par rapport aux intentions de l'étude associée.

Intention de l'étude Arcadia	**Réponse dans notre démarche**
Prédire le phénotype à partir du génotype	Classification binaire supervisée, split groupé par MLST, évaluation sur lignages non vus
Caractériser l'architecture génétique	Coefficients LogReg, importances RF/XGBoost, TreeSHAP (et LIME), confrontation aux mutations QRDR
Tester des modèles non linéaires	MLP sur SNP, MLP sur top-k, autoencodeur + classifieur sur l'embedding
Étudier les interactions gène–gène	LogReg avec termes d'interaction entre mutations QRDR majeures ; analyse des erreurs par lignage et par mécanisme
Utiliser un *phenotype encoder*	Autoencodeur génotypique (équivalent méthodologique), puis classifieur sur la couche latente ; comparaison à la PCA
Passer à l'échelle, modèles de fondation	Hors périmètre (annexe A)

3. Ce que l'étude voulait faire, et comment notre projet s'y articule.

4. Différences de protocole. Les deux travaux ne répondent pas exactement à la même question :

Table 2 – Comparaison des objectifs et des protocoles.

Dimension	**Étude Patton et al. (2025)**	**Notre projet**
Objectif principal	Estimer l'architecture génétique et l'héritabilité	Évaluer la généralisation prédictive sur des lignages non vus
Modèle central	BSLMM probabiliste (GEMMA)	LogReg, forêt aléatoire, XGBoost, MLP
Structure de population	Matrice de *relatedness* dans le modèle mixte	Split groupé par MLST
Évaluation	Effets de marqueurs, héritabilité, transitions	PR-AUC, rappel, F1, balanced accuracy, calibration
Jeu de test	Pas de hold-out de lignages décrit	Test hold-out, jamais utilisé pour la sélection
Deep Learning	Perspective future	MLP, autoencodeur (*phenotype encoder*), comparaison PCA
Interactions	LogReg épistasie (3 mutations)	LogReg + interactions QRDR ; arbres / MLP
Interprétabilité	Effets de marqueurs BSLMM	Coefficients, importances, TreeSHAP, LIME, erreurs par lignage

5. Conséquence pour l'interprétation. Notre projet est **complémentaire** de l'étude Arcadia, pas concurrent. L'étude 2025 cherche à comprendre *quels* variants portent le signal et *comment* la résistance a évolué ; notre projet cherche à savoir *si* un modèle entraîné sur ces variants généralise à de nouveaux lignages, et *à quel coût* en termes de complexité. Les deux approches se rejoignent sur un point : les mutations `parC` Ser80Ile, `gyrA` Ser83Leu et `gyrA` Asp87Asn/Tyr/His dominent le signal. Cette convergence renforce la validité biologique des résultats.

2 Données et enrichissement

2.1 Jeu de données initial

Le jeu de données provient de l'archive Zenodo associée au projet Arcadia Science (Mets & Morin, 2024; Zenodo, 2024). Il contient des génomes séquencés d'*E. coli* et leurs phénotypes de résistance à plusieurs antibiotiques. Pour ce projet, nous nous concentrons sur la ciprofloxacine.

Après restriction aux isolats ayant un phénotype documenté pour la ciprofloxacine, nous obtenons :

— $N = 5\,935$ isolats ;

— 4 colonnes de métadonnées : `sra`, `Genome.Name`, `mlst_group`, `y` ;

— 20 731 variables de présence/absence de gènes ou de clusters pangénomiques ;

— aucune valeur manquante dans la matrice de caractéristiques.

La variable cible est binaire :

$$y_i = \begin{cases} 0 & \text{si l'isolat } i \text{ est sensible à la ciprofloxacine,} \\ 1 & \text{si l'isolat } i \text{ est résistant.} \end{cases}$$

Table 3 – Distribution de la variable cible dans le jeu de données enrichi.

Phénotype	Code	Effectif	Proportion
Sensible	0	4 650	78,35 %
Résistant	1	1 285	21,65 %
Total	–	**5 935**	**100 %**

Le déséquilibre est modéré mais suffisant pour rendre l'exactitude (accuracy) trompeuse : un classifieur qui prédit toujours « sensible » obtient déjà environ 78 % sur l'ensemble complet, et 83 % sur les ensembles de validation et de test du découpage retenu (voir section 3). C'est pourquoi nous privilégions des métriques centrées sur la classe minoritaire.

2.2 Le problème des gènes core et l'absence des mutations QRDR

Le pangénome est une matrice de présence/absence. Les gènes présents chez toutes les souches (gènes *core*) sont invariants et ont été filtrés lors de la construction de la matrice. Or, les gènes `gyrA`, `gyrB`, `parC` et `parE` sont précisément des gènes core : leur présence ne varie pas, mais leurs *séquences* varient. Les mutations QRDR, pourtant centrales dans la résistance aux fluoroquinolones, ne sont donc pas représentées dans la matrice initiale.

Conséquence

Sans les SNP QRDR, le modèle peut apprendre des associations avec des gènes accessoires ou des marqueurs de lignage, mais il ne dispose pas des mécanismes les plus directs de la résistance. Il est donc nécessaire d'enrichir la matrice avec les variants ponctuels pertinents.

2.3 Extraction ciblée des SNP QRDR et régulateurs

Nous n'ajoutons pas les 2,4 millions de variants bruts du VCF pangénomique. Une telle matrice serait trop volumineuse, très redondante et difficile à interpréter. Nous adoptons une stratégie ciblée :

1. **Sélection des contigs** : `gyrA`, `gyrB`, `parC`, `parE`, `marR`, `acrR_1`, `acrR_2`, `soxR`.
2. **Filtrage des variants** : seuls les variants non synonymes (missense, nonsense, frameshift) sont conservés. Les variants synonymes sont exclus car ils ne modifient pas la protéine et sont moins directement interprétables.
3. **Fréquence minimale** : un variant doit être présent chez au moins 5 isolats. Cela évite les variants uniques, qui sont nombreux, instables et peu exploitables statistiquement.
4. **Sites multi-alléliques** : lorsqu'un même site porte plusieurs allèles alternatifs, chaque allèle est encodé comme une variable binaire distincte.
5. **Encodage** : 1 si le variant est détecté, 0 si l'allèle de référence est observé. Le génotype `.` du VCF signifie « pas de variant détecté », et non « donnée manquante ».

Cette procédure produit 198 **variables SNP**. Le jeu de base est conservé intact ; le jeu enrichi est écrit séparément dans `data/processed/ecoli_ciprofloxacin_snp.parquet`. Cette

séparation permet de comparer les modèles avec et sans enrichissement, et de reproduire les résultats du jeu de base.

Table 4 – Exemples de SNP QRDR extraits et nombre de porteurs.

Gène	Substitution	Nombre de porteurs
`gyrA`	Ser83Leu	1 548
`gyrA`	Asp87Asn	1 210
`parC`	Ser80Ile	1 223
`parC`	Glu84Val	536

2.4 Structure finale de la matrice

Table 5 – Structure du jeu de données enrichi.

Bloc	Nombre de colonnes	Encodage
Métadonnées	4	identifiants, MLST, cible
Pangénome	20 731	présence/absence 0/1
SNP QRDR et régulateurs	198	variant absent/présent 0/1
Total	**20 933**	–

La matrice pangénomique est creuse : environ 70,6 % des valeurs sont nulles, avec en moyenne 6 086 gènes ou contigs détectés par isolat. Les variables SNP sont encore plus creuses (environ 95,2 % de zéros), ce qui est attendu pour des mutations rares.

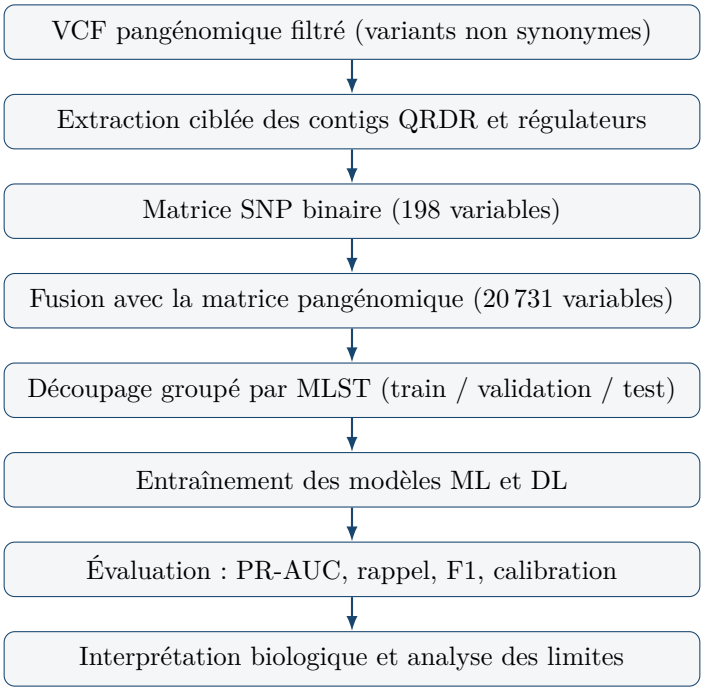


Figure 1 – Pipeline méthodologique, de l'extraction des SNP à l'interprétation.

3 Partitionnement et prévention de la fuite de données

3.1 Le piège du découpage aléatoire

Un découpage aléatoire des isolats peut placer des clones ou des souches très proches à la fois dans l'entraînement et dans le test. Le modèle apprend alors des marqueurs de lignage plutôt que les mécanismes de résistance, et les performances sont surestimées.

Dans notre vérification exploratoire, un découpage aléatoire initial laissait **95,8 %** des isolats de test partager un groupe MLST avec l'ensemble d'entraînement. Ce n'est pas acceptable pour estimer la capacité de généralisation à des lignages non vus.

3.2 Découpage groupé par MLST

Nous utilisons `StratifiedGroupKFold` de scikit-learn (Pedregosa et al., 2011) avec les paramètres suivants :

— 6 folds ;

— 4 folds forment l'entraînement, 1 fold la validation, 1 fold le test ;

— stratification sur la variable cible y ;

— groupes définis par `mlst_group` ;

— les isolats dont le MLST est `unknown` sont traités comme des groupes individuels, un par identifiant `sra`.

Le couple (validation, test) est choisi parmi les 6×5 combinaisons possibles pour se rapprocher des proportions cible 70/15/15 et du taux global de résistance. La graine est fixée à 42 pour la reproductibilité.

Propriété essentielle

Aucun groupe MLST connu n'apparaît dans deux splits différents. Le test est donc un véritable hold-out de lignages, et non une simple répartition aléatoire d'isolats.

3.3 Tailles et composition des splits

Table 6 – Découpage train/validation/test groupé par MLST.

Split	Isolats	Résistants	Taux R	Groupes	dont unknown
Train	4 074	975	23,93 %	520	252
Validation	932	156	16,74 %	157	78
Test	929	154	16,58 %	151	76
Total	**5 935**	**1 285**	**21,65 %**	–	406

Le taux de résistance est plus élevé dans le train (23,9 %) que dans la validation et le test (≈ 16,7 %). Cette différence est une conséquence de la structure des groupes MLST : certains grands groupes résistants sont concentrés dans le train. Il serait dangereux de « rééquilibrer »

artificiellement les splits en cassant les groupes, car on réintroduirait de la fuite. Il faut donc en tenir compte dans l'interprétation des métriques.

3.4 Pourquoi trois ensembles ?

— **Train** : ajustement des paramètres du modèle.

— **Validation** : choix des hyperparamètres, de la régularisation, du seuil de décision et de l'arrêt précoce.

— **Test** : évaluation finale, une seule fois, après gel des choix.

Le test ne doit jamais servir à sélectionner un modèle. Sinon, il devient une seconde validation et la performance annoncée n'est plus une estimation honnête de la généralisation.

4 Démarche en Machine Learning

4.1 Formalisation du problème

On dispose d'une matrice $X \in \{0,1\}^{N \times P}$ et d'un vecteur $y \in \{0,1\}^N$. On cherche une fonction $f_\theta : \{0,1\}^P \to [0,1]$ qui estime la probabilité de résistance :

$$\hat{p}_i = f_\theta(x_i) \approx \mathbb{P}(y_i = 1 \mid x_i).$$

La décision binaire est obtenue par seuillage :

$$\hat{y}_i = \begin{cases} 1 & \text{si } \hat{p}_i \geq \tau, \\ 0 & \text{sinon,} \end{cases}$$

où τ est le seuil de décision. Le choix de τ est un choix *métier* : favoriser le rappel (ne pas manquer de résistants) ou la précision (limiter les fausses alarmes).

4.2 Régression logistique

La régression logistique est le modèle de référence linéaire :

$$\hat{p}_i = \sigma(w^\top x_i + b) = \frac{1}{1 + \exp\left(-(w^\top x_i + b)\right)}.$$

Elle est entraînée en minimisant la log-vraisemblance négative régularisée :

$$\mathcal{L}(w, b) = -\frac{1}{N} \sum_{i=1}^{N} \left[y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i) \right] + \lambda \|w\|_2^2.$$

Le terme $\lambda \|w\|_2^2$ est une régularisation L2 qui limite la magnitude des coefficients et réduit le sur-apprentissage.

Justification. La régression logistique est simple, rapide, stable et interprétable : le coefficient w_j correspond à la variation du log-odds de résistance lorsque la variable j passe de 0 à 1. Elle

fournit une base honnête pour juger si des modèles plus complexes apportent un gain réel. Si un modèle complexe ne fait pas mieux, il n'est pas justifié de l'utiliser.

Limite. Le modèle additif ne capture pas automatiquement les interactions entre mutations. Pour y répondre dans la démarche, nous ajoutons explicitement des termes d'interaction (ci-dessous) et nous comparons à des modèles d'arbres et à un MLP, qui les capturent de façon non paramétrique.

4.3 Régression logistique avec interactions QRDR

Pour tester l'épistasie entre les mutations majeures de la ciprofloxacine, nous enrichissons la LogReg SNP-only avec des termes d'interaction deux à deux entre les variants QRDR les plus fréquents, notamment :

— `parC` Ser80Ile × `gyrA` Ser83Leu ;

— `parC` Ser80Ile × `gyrA` Asp87Asn ;

— `gyrA` Ser83Leu × `gyrA` Asp87Asn.

Le modèle devient :

$$\hat{p}_i = \sigma\left(b + \sum_j w_j x_{ij} + \sum_{(j,k)\in\mathcal{I}} w_{jk}\, x_{ij} x_{ik}\right),$$

où $\mathcal{I}$ est l'ensemble des paires d'interaction retenues. Les coefficients w_{jk} s'interprètent comme un surplus (ou un déficit) de log-odds lorsque les deux mutations coexistent.

Place dans la démarche. Cette expérience est **obligatoire** dans le protocole : elle répond directement à l'intention Arcadia « interactions gène–gène », reste interprétable, et fournit un point de comparaison aux arbres / MLP qui modélisent les interactions sans les nommer.

4.4 Forêt aléatoire

Une forêt aléatoire (Breiman, 2001) combine B arbres de décision entraînés sur des échantillons bootstrap et des sous-ensembles aléatoires de variables. Chaque arbre partitionne l'espace selon des seuils qui maximisent une diminution d'impureté, par exemple l'indice de Gini :

$$G(t) = 1 - \sum_{k=0}^{1} p_{k|t}^2,$$

où $p_{k|t}$ est la proportion de classe k dans le nœud t. La prédiction agrège les arbres :

$$\hat{p}_i = \frac{1}{B}\sum_{b=1}^{B} \hat{p}_{i,b}.$$

Justification. Les forêts capturent des relations non linéaires et des interactions, sont robustes aux valeurs aberrantes et fournissent une importance de variables par diminution moyenne d'impureté. Elles sont un bon représentant des modèles d'ensemble « classiques ».

Limites. Avec beaucoup de variables corrélées, l'importance peut être diluée entre variables redondantes. Les forêts peuvent aussi sur-apprendre lorsque les arbres sont très profonds, surtout avec un grand nombre de variables et un échantillon modéré. Il faut donc régler `max_depth`, `min_samples_leaf`, `max_features` et éventuellement utiliser des poids de classe.

4.5 XGBoost

XGBoost (Chen & Guestrin, 2016) est un modèle de *gradient boosting* qui construit séquentiellement des arbres en corrigeant les erreurs des arbres précédents. À l'étape t, on minimise :

$$\mathcal{L}^{(t)} = \sum_{i=1}^{N} \ell\left(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)\right) + \Omega(f_t),$$

avec

$$\Omega(f) = \gamma T + \frac{1}{2}\lambda \|w\|^2,$$

où T est le nombre de feuilles, w les poids des feuilles, γ un seuil de complexité et λ une régularisation L2.

L'objectif est approché au second ordre :

$$\mathcal{L}^{(t)} \approx \sum_{i=1}^{N} \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t(x_i)^2 \right] + \Omega(f_t),$$

où g_i et h_i sont les dérivées première et seconde de la perte par rapport à la prédiction courante. Le gain d'une division entre un nœud parent I et deux enfants L et R s'écrit :

$$\mathcal{G} = \frac{1}{2}\left[\frac{(\sum_{i\in L} g_i)^2}{\sum_{i\in L} h_i + \lambda} + \frac{(\sum_{i\in R} g_i)^2}{\sum_{i\in R} h_i + \lambda} - \frac{(\sum_{i\in I} g_i)^2}{\sum_{i\in I} h_i + \lambda} \right] - \gamma.$$

Justification. XGBoost est généralement très performant sur les données tabulaires, gère bien les interactions et les variables corrélées, et offre un contrôle fin du sur-apprentissage via la profondeur, le taux d'apprentissage, la régularisation et l'arrêt précoce. C'est un excellent candidat pour établir un plafond de performance réaliste.

Paramètres à explorer.

— `n_estimators`, `max_depth`, `learning_rate` ;
— `subsample`, `colsample_bytree`, `min_child_weight` ;
— `gamma`, `reg_lambda`, `reg_alpha`, `scale_pos_weight`.

L'arrêt précoce sur la validation évite de multiplier les arbres inutilement.

4.6 Jeux de caractéristiques et ablations

Pour comprendre d'où vient le signal, nous comparons plusieurs représentations :

1. **Complet** : 20 731 variables pangénomiques + 198 SNP = 20 929 variables ;
2. **SNP seuls** : 198 SNP QRDR et régulateurs ;
3. **Pangénome seul** : 20 731 variables de présence/absence ;

4. **Top-k** : sélection des k variables les plus importantes selon un modèle entraîné uniquement sur le train, avec $k \in \{100, 500, 2000\}$.

Cette ablation est essentielle : elle permet de distinguer un gain dû à une meilleure modélisation d'un gain dû simplement à l'ajout de variables biologiquement pertinentes.

4.7 Gestion du déséquilibre

Plusieurs stratégies sont comparées :

— pas de pondération ;

— pondération de la classe minoritaire (`class_weight="balanced"` ou `scale_pos_weight`) ;

— ajustement du seuil de décision sur la validation ;

— éventuellement sur-échantillonnage de la classe minoritaire, mais uniquement dans le train, jamais avant le split.

Le sur-échantillonnage naïf peut créer des doublons et favoriser le sur-apprentissage. La pondération et le seuillage sont généralement plus simples et plus contrôlables.

5 Démarche en Deep Learning

5.1 Un MLP est-il pertinent ?

Un perceptron multicouche (MLP) est un approximateur universel de fonctions continues. Il peut modéliser des interactions non linéaires entre variables. Sur des données tabulaires, il est cependant moins naturel qu'un modèle à base d'arbres : il ne possède aucune structure inductive adaptée aux colonnes, qui sont traitées comme un vecteur non ordonné.

Un MLP est néanmoins pertinent pour :

— comparer une famille neuronale aux modèles classiques ;

— tester si une représentation non linéaire apprend mieux les interactions ;

— servir de support pédagogique pour PyTorch, la régularisation et l'arrêt précoce ;

— produire des embeddings intermédiaires exploitables pour l'analyse.

5.2 Architecture et entraînement

Une architecture raisonnable pour 198 SNP est :

$$x \in \mathbb{R}^{198} \longrightarrow h_1 = \phi(W_1 x + b_1) \in \mathbb{R}^{64} \longrightarrow h_2 = \phi(W_2 h_1 + b_2) \in \mathbb{R}^{32} \longrightarrow \hat{p} = \sigma(w_3^\top h_2 + b_3),$$

où ϕ est une activation ReLU. On ajoute éventuellement :

— du dropout (Srivastava et al., 2014) pour réduire la co-adaptation des neurones ;

— de la normalisation par lots (Ioffe & Szegedy, 2015) pour stabiliser l'entraînement ;

— une régularisation L2 (`weight_decay`) ;

— un arrêt précoce sur la perte de validation.

La perte est une entropie croisée binaire avec logits :

$$\mathcal{L} = -\frac{1}{N}\sum_{i=1}^{N}\left[w_+\, y_i \log \hat{p}_i + (1-y_i)\log(1-\hat{p}_i)\right],$$

où $w_+ > 1$ est un poids pour la classe résistante. Cette pondération augmente le coût des faux négatifs, ce qui est souvent souhaitable en santé.

L'optimisation utilise Adam (Kingma & Ba, 2015), avec un taux d'apprentissage initial de l'ordre de 10^{-3}, une taille de lot de 64 ou 128, et un nombre maximal d'époques modéré. Le meilleur modèle est sélectionné sur la validation, puis évalué sur le test.

5.3 Autoencodeur : apprentissage de représentation (*phenotype encoder*)

L'étude Arcadia évoque un *phenotype encoder*. Dans notre démarche, l'équivalent opérationnel est un **autoencodeur génotypique** suivi d'un classifieur : on apprend d'abord une représentation comprimée des variables, puis on prédit le phénotype à partir de cette représentation.

Un autoencodeur est un réseau non supervisé :

$$z = f_\theta(x), \qquad \hat{x} = g_\phi(z),$$

entraîné en minimisant l'erreur de reconstruction :

$$\mathcal{L}_{AE} = \frac{1}{N}\sum_{i=1}^{N} \|x_i - \hat{x}_i\|_2^2.$$

La couche latente z sert ensuite d'entrée à une régression logistique ou à un petit MLP. Le protocole compare systématiquement :

— les variables brutes (SNP, pangénome, complet, top-k) ;

— une réduction de dimension linéaire (PCA) ;

— une réduction non linéaire (autoencodeur) + classifieur sur l'embedding.

Cette expérience fait partie du **cœur Deep Learning** de la démarche : elle teste si une représentation apprise apporte un gain par rapport aux variables brutes ou à la PCA, sans dépendre d'un modèle de fondation.

5.4 Interprétabilité de l'autoencodeur

Un autoencodeur ne se prête pas aux outils conçus pour les modèles supervisés : il ne prédit pas le phénotype, ses poids ne sont pas directement associés aux variables d'entrée, et TreeSHAP ne s'applique pas (ce n'est pas un modèle d'arbres). L'interprétation doit donc distinguer deux questions différentes :

1. **que représente la couche latente z ?** C'est une question sur la *représentation*.
2. **qu'est-ce qui pilote la prédiction du pipeline ?** C'est une question sur le couple autoencodeur + classifieur.

Interpréter la représentation.

— **Projection de l'espace latent** (PCA ou t-SNE de z) colorée successivement par le MLST, par le phénotype et par le nombre de mutations QRDR. C'est le test le plus informatif : si z se sépare d'abord par lignage, l'autoencodeur encode la structure de population ; s'il se sépare par profil QRDR, il encode le mécanisme.

— **Sondage du décodeur** : pour chaque dimension latente, examiner les poids du décodeur vers les variables d'entrée afin d'étiqueter les unités (« cette dimension suit `parC` Ser80Ile »). C'est l'équivalent non linéaire des *loadings* d'une ACP.

— **Erreur de reconstruction par isolat** : un isolat mal reconstruit est un génome atypique (lignage rare, plasmide, assemblage douteux). Cette information sert directement à l'analyse d'erreurs.

— **Comparaison avec la PCA** : aligner les sous-espaces de l'autoencodeur et de la PCA (corrélation canonique ou Procrustes) pour déterminer si le non-linéaire apporte des directions réellement nouvelles.

Interpréter la prédiction. Sur le pipeline complet (autoencodeur puis classifieur) : gradients intégrés ou KernelSHAP, ablation d'une dimension latente avec mesure de la chute de PR-AUC, et LIME local sur quelques cas d'erreur. Ces outils sont des *approximations* sur un réseau, contrairement à TreeSHAP qui est exact sur les arbres.

Risque principal : un encodeur de lignage

Dans un pangénome, la source de variance dominante est la structure de population. Un autoencodeur risque donc de compresser d'abord le **lignage** plutôt que le mécanisme de résistance. Le test de projection colorée doit être réalisé *avant* toute conclusion biologique sur z.

Place dans la démarche. Comme pour les autres modèles, l'interprétation n'est réalisée que si l'autoencodeur est **retenu** à l'issue de la comparaison avec la PCA et les variables brutes (section 5.1). Dans le cas contraire, l'effort d'interprétation est investi sur le modèle finalement sélectionné.

Les approches volontairement exclues du périmètre (CNN sur matrice tabulaire, modèles de fondation, multi-tâches systématique) sont justifiées en annexe A.

6 Protocole d'évaluation

6.1 Matrice de confusion et métriques

Pour un seuil τ, on définit :

— TP : vrais positifs (résistants correctement prédits) ;

— FP : faux positifs (sensibles prédits résistants) ;

— FN : faux négatifs (résistants prédits sensibles) ;

— TN : vrais négatifs (sensibles correctement prédits).

Les métriques principales sont :

$$\text{Précision} = \frac{TP}{TP + FP}, \qquad \text{Rappel} = \frac{TP}{TP + FN},$$

$$F_1 = \frac{2 \times \text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}},$$

$$\text{Balanced accuracy} = \frac{1}{2}\left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP}\right).$$

L'exactitude est :

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}.$$

Pour évaluer le classement indépendamment du seuil, on utilise la courbe précision-rappel et son aire (PR-AUC), ainsi que la courbe ROC et son aire (ROC-AUC). La PR-AUC est particulièrement informative lorsque la classe positive est minoritaire (Saito & Rehmsmeier, 2015). L'AP (average precision) est estimée par :

$$\text{AP} = \sum_n (R_n - R_{n-1}) P_n,$$

où P_n et R_n sont la précision et le rappel au n-ième seuil.

La calibration est évaluée par le score de Brier :

$$\text{Brier} = \frac{1}{N} \sum_{i=1}^{N} (\hat{p}_i - y_i)^2.$$

Un bon score de Brier indique que les probabilités sont globalement fiables, pas seulement bien classées.

6.2 Pourquoi l'exactitude seule est trompeuse

Dans le split retenu, le classifieur majoritaire « toujours sensible » obtient :

$$\text{accuracy}_{\text{val}} = \frac{776}{932} \approx 83{,}3\,\%, \qquad \text{accuracy}_{\text{test}} = \frac{775}{929} \approx 83{,}4\,\%.$$

Un modèle qui atteindrait 84 % d'exactitude pourrait donc n'avoir qu'un rappel très faible sur les résistants. C'est exactement ce que nous observons avec la régression logistique complète : 84,5 % d'exactitude en validation, mais seulement 31,4 % de rappel. Un tel modèle rate plus des deux tiers des résistants.

6.3 Choix du seuil

Le seuil par défaut $\tau = 0{,}5$ n'est pas nécessairement optimal. Nous choisissons τ sur la validation selon un critère explicite :

— maximiser le F1 de la classe résistante ;

— ou atteindre un rappel cible (par exemple 90 %) tout en maximisant la précision ;

— ou minimiser le coût métier $C = c_{FN} FN + c_{FP} FP$, si des coûts sont disponibles.

Le seuil choisi est ensuite **gelé** et appliqué au test. Il ne doit pas être réoptimisé sur le test.

6.4 Incertitude et variabilité

Avec 154 résistants dans le test, les intervalles de confiance sont larges. Nous rapportons :

— des intervalles de confiance bootstrap à 95 % pour les métriques ;

— la moyenne et l'écart-type sur plusieurs graines aléatoires ;

— les résultats par sous-groupe de lignage (MLST / clonal complex).

Une différence de 1 ou 2 points de PR-AUC entre deux modèles n'est pas nécessairement significative. Il faut éviter de surinterpréter des écarts faibles.

6.5 Analyse des erreurs et des sous-groupes

Après l'évaluation globale, la démarche inclut une **analyse d'erreurs** sur le test (et, pour exploration, sur la validation) :

1. recenser les faux négatifs (résistants manqués) et les faux positifs ;
2. les stratifier par lignage MLST et, lorsque c'est possible, par profil de mutations QRDR ;
3. vérifier si les erreurs concentrent des mécanismes absents du train, des lignages rares, ou des cas sans mutation QRDR classique ;
4. pour un échantillon de cas critiques, produire une explication locale (TreeSHAP ou LIME) afin de comprendre quelles variables ont poussé la décision.

Cette analyse relie performance et biologie : elle complète l'étude des interactions et la validation QRDR.

6.6 Diagnostic du sur-apprentissage

Le sur-apprentissage se diagnostique en comparant :

$$\Delta_{\text{gen}} = \text{PR-AUC}_{\text{train}} - \text{PR-AUC}_{\text{val/test}}.$$

Un modèle qui atteint 1,000 en train et 0,550 en validation est fortement sur-appris ou, au minimum, mal calibré pour la classe minoritaire. Un modèle qui atteint 0,990 en train et 0,950 en test généralise correctement.

Nous traçons également des courbes d'apprentissage (performance en fonction de la taille du train) pour distinguer :

— un problème de *biais* (modèle trop simple, performance faible partout) ;

— un problème de *variance* (performance élevée en train, faible en validation) ;

— un problème de *données* (performance plafonnée même avec plus de données).

7 Interprétabilité et validation biologique

7.1 Pourquoi interpréter ?

Un modèle prédictif utile en microbiologie ne doit pas seulement être performant : il doit aider à comprendre les mécanismes. L'interprétabilité poursuit trois objectifs :

1. vérifier que le modèle s'appuie sur des mécanismes biologiques plausibles ;
2. détecter des artefacts ou des marqueurs de lignage ;
3. fournir des hypothèses aux biologistes.

7.2 Quand interpréter dans la démarche ?

L'interprétation n'intervient **ni pendant l'entraînement, ni à la place de l'évaluation**. Elle vient **après** :

1. entraînement des modèles (régression logistique, forêt aléatoire, XGBoost, MLP) sur le train ;
2. sélection des hyperparamètres et du seuil sur la validation ;
3. évaluation finale sur le test (PR-AUC, rappel, F1, calibration) ;
4. **puis** analyse des importances et explications locales (SHAP, éventuellement LIME) sur le modèle retenu.

On applique SHAP / LIME en priorité au **meilleur modèle d'arbres** (forêt aléatoire ou XGBoost) et, si besoin, au MLP pour comparaison. Les coefficients de la régression logistique restent le baseline d'interprétabilité le plus simple. L'autoencodeur fait l'objet d'un traitement spécifique, car il ne prédit pas directement le phénotype : voir la section 5.4.

7.3 Outils selon les modèles

Table 7 – Outils d'interprétabilité associés aux familles de modèles.

Modèle	Outils principaux
Régression logistique	coefficients, odds ratios, intervalles de confiance
Forêt aléatoire	importance (impureté), permutation, TreeSHAP, LIME
XGBoost	gain, couverture, fréquence, permutation, TreeSHAP, LIME
MLP	importance par permutation, gradients intégrés, KernelSHAP, LIME
Autoencodeur (+ classifieur)	espace latent (projection colorée, sondage du décodeur), erreur de reconstruction, gradients intégrés / KernelSHAP sur le pipeline, ablation de dimensions, LIME local

7.4 SHAP : ce que cela permet

SHAP (*SHapley Additive exPlanations*) (Lundberg & Lee, 2017) attribue à chaque variable une contribution ϕ_j à la prédiction d'un isolat, de sorte que

$$\hat{f}(x) = \phi_0 + \sum_{j=1}^{P} \phi_j .$$

Pour les forêts et XGBoost, **TreeSHAP** calcule ces contributions de façon exacte et efficace.

Ce que SHAP nous apporte.

— une **importance globale** (moyenne des $|\phi_j|$) pour classer les SNP et contigs qui pilotent le modèle ;

— une **explication locale** par isolat : pourquoi cette souche est prédite résistante ou sensible ;

— une lecture du **signe** de l'effet (mutation qui pousse vers la résistance ou vers la sensibilité) ;

— une confrontation directe aux mutations QRDR attendues (`parC` Ser80Ile, `gyrA` Ser83Leu, Asp87Asn, etc.).

Protocole prévu. Sur le modèle d'arbres retenu : (i) importances natives (impureté / gain) ; (ii) importance par permutation sur la validation ; (iii) TreeSHAP sur un échantillon de la validation et du test ; (iv) synthèse du top des variables et validation biologique.

7.5 LIME : rôle complémentaire

LIME (*Local Interpretable Model-agnostic Explanations*) (Ribeiro et al., 2016) approxime localement le modèle par un modèle linéaire sparse autour d'un isolat. Contrairement à TreeSHAP, LIME est **agnostique** du type de modèle : il s'applique aussi bien à une forêt, à XGBoost ou à un MLP.

Ce que LIME nous apporte.

— une explication locale rapide, utile pour auditer quelques cas critiques (faux négatifs, faux positifs) ;

— une vérification croisée avec SHAP : si les deux méthodes mettent en avant les mêmes SNP QRDR, la confiance dans l'interprétation augmente.

Limite. LIME dépend du voisinage et de la perturbation ; il est moins stable que TreeSHAP sur des arbres. Nous le traitons donc comme **complément**, pas comme outil principal pour RF / XGBoost.

7.6 Précautions

Corrélation n'est pas causalité

Une variable importante pour le modèle n'est pas nécessairement une cause de la résistance. Elle peut être un marqueur de lignage, un gène accessoire corrélé, ou un proxy d'un mécanisme non observé. L'interprétation doit être confrontée à la littérature et, idéalement, à des expériences fonctionnelles.

De plus, lorsque des variables sont fortement corrélées, l'importance se répartit entre elles. Une mutation connue peut avoir une importance individuelle faible simplement parce qu'une autre variable corrélée porte une partie du signal.

7.7 Validation biologique attendue

Nous comparons les variables les plus importantes aux mécanismes connus :

— `parC` Ser80Ile ;

— `gyrA` Ser83Leu ;

— `gyrA` Asp87Asn/Tyr/His ;

— éventuellement `parC` Glu84Val/Lys/Gly et les régulateurs `marR`, `acrR`, `soxR`.

Si le modèle s'appuie d'abord sur ces mutations, c'est un signe de validité biologique. Si les premières variables sont des gènes accessoires non annotés, il faut investiguer un possible marqueur de lignage ou un artefact.

8 Plan expérimental

8.1 Phases du projet

Table 8 – Plan de travail et livrables.

Phase	Objectif	Livrables
0	Audit des données	dimensions, manquants, distribution de y, doublons, groupes MLST
1	Construction du jeu enrichi	matrice SNP, manifeste, documentation, jeu de base préservé
2	Découpage groupé	splits train/validation/test, absence de chevauchement MLST
3	Baselines ML	LogReg, LogReg+interactions QRDR, forêt aléatoire, XGBoost
4	Deep Learning	MLP (SNP, top-k, complet), autoencodeur + classifieur, comparaison PCA
5	Ablations	SNP seuls, pangénome seul, complet, top-k, avec/sans pondération
6	Interprétabilité	coefficients, importances, TreeSHAP, LIME, confrontation QRDR
7	Analyse d'erreurs	faux négatifs/positifs par lignage et par mécanisme
8	Robustesse	bootstrap 95 %, plusieurs graines, calibration, seuil sur validation
9	Rédaction	rapport, figures, slides, dépôt reproductible

8.2 Matrice des expériences

Table 9 – Combinaisons minimales à évaluer.

Représentation	**LogReg**	**Forêt aléatoire**	**XGBoost**	**MLP**
SNP seuls (198)	oui	oui	oui	oui
Pangénome seul (20 731)	oui	oui	oui	oui
Complet (20 929)	oui	oui	oui	oui
Top-k ($k = 500$)	oui	oui	oui	oui

Expériences complémentaires **incluses dans la démarche** :

— LogReg SNP-only *avec* interactions QRDR majeures ;

— autoencodeur puis classifieur sur l'embedding, comparé à PCA + classifieur ;

— TreeSHAP (et LIME sur cas d'erreur) sur le meilleur modèle d'arbres ;

— analyse des erreurs par lignage MLST et par profil QRDR.

Chaque cellule doit être évaluée avec :

— les mêmes splits ;

— plusieurs graines (au moins 3 pour les modèles stochastiques) ;

— les mêmes métriques ;

— le seuil choisi uniquement sur la validation.

8.3 Reproductibilité

Les expériences doivent être reproductibles :

— graine fixée pour le split et pour les modèles ;

— sauvegarde des hyperparamètres et des versions de bibliothèques ;

— sauvegarde des prédictions de validation et de test ;

— script unique ou notebook exécutable de bout en bout ;

— documentation des fichiers d'entrée et de sortie.

8.4 Extensions au-delà du cœur de la démarche

Les éléments ci-dessus (baselines, interactions QRDR, MLP, autoencodeur, SHAP/LIME, analyse d'erreurs, bootstrap, calibration) constituent le **périmètre méthodologique retenu**. Au-delà, et seulement si le temps le permet :

1. **Validation croisée groupée** multi-folds / multi-graines pour estimer la variabilité du split.
2. **Validation externe** sur une cohorte indépendante.
3. **Modèle multi-tâches** : plusieurs antibiotiques avec un tronc commun.
4. **Baseline BSLMM/GEMMA** pour se comparer plus directement à Arcadia (Patton et al., 2025; Zhou et al., 2013).

Les approches explicitement *non retenues* (CNN sur données tabulaires, modèles de fondation, etc.) sont détaillées en annexe A.

9 Résultats préliminaires et lecture critique

9.1 Modèles complets

Les résultats suivants ont été obtenus avec le split groupé par MLST, les hyperparamètres par défaut et un seuil de 0,5. Ils sont préliminaires et servent à valider la démarche.

Table 10 – Résultats des modèles complets (20 929 variables).

Modèle	Split	PR-AUC	ROC-AUC	Accuracy	Rappel R	F1 R	Bal. acc.
LogReg	Train	1,000	1,000	1,000	1,000	1,000	1,000
LogReg	Validation	0,554	0,844	0,845	0,314	0,405	0,633
LogReg	Test	0,830	0,921	0,926	0,669	0,749	0,823
RF	Train	1,000	1,000	1,000	1,000	1,000	1,000
RF	Validation	0,803	0,940	0,897	0,385	0,556	0,692
RF	Test	0,833	0,934	0,930	0,604	0,741	0,799
XGBoost	Train	1,000	1,000	1,000	1,000	1,000	1,000
XGBoost	Validation	**0,969**	**0,986**	**0,974**	**0,917**	**0,923**	**0,951**
XGBoost	Test	**0,951**	**0,972**	**0,952**	**0,916**	**0,862**	**0,937**

9.2 Comparaison des représentations

Table 11 – Effet de la représentation sur la performance (seuil 0,5).

Représentation	Modèle	PR-AUC val	PR-AUC test	Rappel val	Rappel test
SNP seuls	LogReg	0,961	0,941	0,910	0,942
SNP seuls	XGBoost	0,948	0,922	0,936	0,942
Pangénome seul	LogReg	0,512	0,775	0,308	0,656
Pangénome seul	XGBoost	0,579	0,810	0,372	0,643
Complet	LogReg	0,554	0,830	0,314	0,669
Complet	XGBoost	**0,969**	**0,951**	0,917	0,916

9.3 Lecture des résultats

1. Tous les modèles atteignent 1,000 en train. Avec 20 929 variables pour 4 074 échantillons, les modèles ont assez de capacité pour mémoriser le train. Le score d'entraînement n'est donc pas un indicateur utile de qualité. Ce qui compte est l'écart avec la validation et le test.

2. XGBoost est le meilleur modèle complet. Il conserve un PR-AUC de 0,969 en validation et 0,951 en test, avec un rappel de 91,6 % sur le test. C'est le seul modèle complet qui reste solide sur les deux ensembles.

3. La régression logistique complète et la forêt aléatoire sont piégées par le déséquilibre. La régression logistique a une exactitude de 84,5 % en validation, mais un rappel de seulement 31,4 %. La forêt aléatoire a une précision de 100 % en validation, mais un rappel de 38,5 % : elle prédit peu de positifs, mais ceux qu'elle prédit sont corrects. Ces deux comportements illustrent pourquoi l'exactitude et la précision seules sont insuffisantes.

4. Le signal est concentré dans les 198 **SNP.** Une régression logistique sur 198 SNP atteint 0,961 de PR-AUC en validation et 0,941 en test, avec un rappel de 94,2 % en test. C'est presque aussi bien que XGBoost complet, avec environ 100 fois moins de variables. Le pangénome seul, en revanche, généralise moins bien (0,512/0,579 en validation) et semble apprendre des marqueurs de lignage.

5. Le gain du modèle complexe est marginal. XGBoost complet améliore le PR-AUC de test de 0,010 par rapport à la régression logistique SNP-only, mais avec un rappel légèrement inférieur (0,916 contre 0,942). Compte tenu de la taille du test (154 résistants), cet écart n'est probablement pas significatif. La conclusion pratique est qu'un modèle simple sur les SNP est un excellent baseline, et que la complexité doit être justifiée par un gain robuste, pas par une différence de quelques centièmes.

9.4 Interprétation préliminaire

Les variables les plus importantes de XGBoost (*gain* natif, avant TreeSHAP) sont :

— `SNP_parC_Ser80Ile` : 28,0 % ;
— plusieurs contigs pangénomiques non annotés, chacun autour de 0,7 à 4,1 % ;
— `SNP_gyrA_Asp87Asn` : 1,8 % ;
— `SNP_gyrA_Ser83Leu` : 0,8 %.

Le modèle s'appuie d'abord sur une mutation QRDR connue, ce qui est biologiquement rassurant. Les contigs pangénomiques intercalés doivent être interprétés avec prudence : ils peuvent être des marqueurs de lignage, des gènes accessoires corrélés, ou des fragments non annotés. L'étape suivante prévue est TreeSHAP (et LIME sur quelques cas d'erreur) pour confirmer ces importances au niveau global et local.

10 Limites

10.1 Limites méthodologiques

— **Taille du test** : 929 isolats, dont 154 résistants. Les intervalles de confiance sont larges.
— **Un seul antibiotique** : les conclusions ne sont pas nécessairement transposables à d'autres molécules.
— **Découpage par MLST, pas par phylogénie fine** : le MLST est un proxy de clonalité, mais il ne capture pas toute la structure phylogénétique.
— **Pas de validation externe réalisée à ce stade** : le test provient de la même cohorte (prévue au plan expérimental).

— **Seuil non optimisé** : les résultats présentés utilisent $\tau = 0{,}5$. Un seuil choisi sur la validation pourrait améliorer le rappel.

— **Annotations incomplètes** : certains contigs pangénomiques ne sont pas annotés, ce qui limite l'interprétation.

— **Variables corrélées** : l'importance des variables peut être répartie entre variables redondantes.

10.2 Limites du Deep Learning

— Les données sont tabulaires et déjà construites et annotées ; l'avantage inductif des réseaux est limité.

— Le jeu est de taille modérée (5 935 isolats).

— Les MLP sont moins interprétables que les modèles linéaires ou les arbres ; SHAP / LIME atténuent cette limite sans la supprimer.

Les approches hors périmètre et les raisons de leur exclusion sont regroupées en annexe A.

11 Conclusion

Ce rapport propose une démarche complète pour prédire la résistance à la ciprofloxacine chez *E. coli* à partir de données génotypiques. La démarche repose sur quatre piliers :

1. **des données enrichies et justifiées** : ajout ciblé de 198 SNP QRDR non synonymes, sans modifier le jeu de base ;
2. **un découpage honnête** : split train/validation/test groupé par MLST, pour éviter la fuite de clones ;
3. **une comparaison contrôlée** : LogReg (± interactions QRDR), forêt aléatoire, XGBoost, MLP, autoencodeur (+ PCA), sur les mêmes splits et métriques ;
4. **une interprétation et une analyse d'erreurs** : TreeSHAP/LIME, confrontation QRDR, faux négatifs par lignage ;
5. **une évaluation adaptée** : PR-AUC, rappel, F1, balanced accuracy, calibration, bootstrap.

Les résultats préliminaires montrent que le signal est fortement concentré dans les SNP QRDR : une régression logistique sur 198 variables atteint déjà un excellent PR-AUC, et XGBoost complet n'apporte qu'un gain marginal. Le pangénome seul généralise moins bien, ce qui suggère qu'il contient des marqueurs de lignage ou du bruit. Ces observations justifient une conclusion nuancée sur le Deep Learning : il est intéressant à des fins de comparaison et d'apprentissage de représentation, mais il n'est pas le choix prioritaire pour ce jeu de données tabulaire.

Message central

Le bon modèle n'est pas le plus complexe. C'est celui qui capture le signal biologique, généralise sur des lignages non vus, reste interprétable et est évalué honnêtement.

Références

Aldred, K. J., Kerns, R. J., & Osheroff, N. (2014). Mechanism of quinolone action and resistance. *Biochemistry*, 53(10), 1565–1574.

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.

Chen, T., & Guestrin, C. (2016). XGBoost : A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.

Cingolani, P., Platts, A., Wang, L. L., Coon, M., Nguyen, T., Wang, L., ... & Ruden, D. M. (2012). A program for annotating and predicting the effects of single nucleotide polymorphisms, SnpEff. *Fly*, 6(2), 80–92.

Danecek, P., Bonfield, J. K., Liddle, J., Marshall, J., Ohan, V., Pollard, M. O., ... & Li, H. (2021). Twelve years of SAMtools and BCFtools. *GigaScience*, 10(2), giab008.

Hooper, D. C., & Jacoby, G. A. (2016). Topoisomerase inhibitors : Fluoroquinolone mechanisms of action and resistance. *Cold Spring Harbor Perspectives in Medicine*, 6(9), a025320.

Ioffe, S., & Szegedy, C. (2015). Batch normalization : Accelerating deep network training by reducing internal covariate shift. *Proceedings of the 32nd International Conference on Machine Learning*, 448–456.

Kingma, D. P., & Ba, J. (2015). Adam : A method for stochastic optimization. *International Conference on Learning Representations*.

Li, H., & Durbin, R. (2009). Fast and accurate short read alignment with Burrows–Wheeler transform. *Bioinformatics*, 25(14), 1754–1760.

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.

Maiden, M. C., Bygraves, J. A., Feil, E., Morelli, G., Russell, J. E., Urwin, R., ... & Spratt, B. G. (1998). Multilocus sequence typing : A portable approach to the identification of clones within populations of pathogenic microorganisms. *Proceedings of the National Academy of Sciences*, 95(6), 3140–3145.

Mets, D. G., & Morin, M. (2024). *Creating a 7,000-strain E. coli genotype dataset with antimicrobial resistance phenotypes*. Arcadia Science. https://doi.org/10.57844/arcadia-d2cf-ebe5

Murray, C. J., Ikuta, K. S., Sharara, F., Swetschinski, L., Aguilar, G. R., Gray, A., ... & Naghavi, M. (2022). Global burden of bacterial antimicrobial resistance in 2019 : A systematic analysis. *The Lancet*, 399(10325), 629–655.

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... & Chintala, S. (2019). PyTorch : An imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems*, 32.

Patton, A. H., York, R., & Sandler, G. (2025). *Predicting antimicrobial resistance phenotypes across 7,000 E. coli genomes*. Arcadia Science. https://doi.org/10.57844/arcadia-8391-465f

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn : Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you ?" : Explaining the predictions of any classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1135–1144.

Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE*, 10(3), e0118432.

Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout : A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(1), 1929–1958.

Tettelin, H., Masignani, V., Cieslewicz, M. J., Donati, C., Medini, D., Ward, N. L., ... & Fraser, C. M. (2005). Genome analysis of multiple pathogenic isolates of *Streptococcus agalactiae* : Implications for the microbial "pan-genome". *Proceedings of the National Academy of Sciences*, 102(39), 13950–13955.

Zhou, X., Carbonetto, P., & Stephens, M. (2013). Polygenic modeling with Bayesian sparse linear mixed models. *PLoS Genetics*, 9(2), e1003264.

Morin, M. (2024). *Creating a 7,000 strains genotype-phenotype dataset of E. coli and antimicrobial resistance phenotypes* [Data set]. Zenodo. https://doi.org/10.5281/zenodo.12692732

A Approches non retenues dans la démarche

Cette annexe précise ce que nous **ne faisons pas** dans le projet, et pourquoi. Ces choix délimitent le périmètre ; ils ne jugent pas de l'intérêt scientifique de ces approches dans d'autres contextes.

A.1 CNN sur la matrice tabulaire

Un CNN exploite une structure spatiale : localité, partage de poids, invariance par translation. Il est adapté aux images, aux signaux et aux séquences. Dans notre matrice, les colonnes sont des gènes ou des SNP *sans ordre spatial significatif*. Appliquer une convolution à ce vecteur impose une notion de voisinage sans justification biologique.

Un CNN pourrait servir de *contrôle négatif*, mais pas de modèle principal. Pour un CNN ou un transformer réellement motivé, il faudrait travailler sur les **séquences brutes** d'ADN : c'est un autre projet, plus coûteux en calcul et en données.

A.2 Modèles de fondation génomiques

Les modèles de fondation sont utiles lorsqu'on travaille sur des séquences brutes, avec peu de labels, un préentraînement transférable, plusieurs espèces ou tâches, et des ressources GPU importantes.

Ici, la matrice est déjà construite (20 731 variables pangénomiques et 198 SNP annotés). Le jeu compte 5 935 isolats, ce qui est modeste pour un fine-tuning. Le signal est concentré dans quelques mutations QRDR connues. Un modèle de fondation serait **surdimensionné**, coûteux, difficile à reproduire et moins interprétable qu'une forêt ou qu'un XGBoost avec TreeSHAP.

A.3 Apprentissage multi-tâches comme expérience principale

Le jeu contient des phénotypes pour plusieurs antibiotiques. Un modèle multi-tâches avec tronc commun pourrait mutualiser l'information entre phénotypes corrélés. Nous le listons comme **perspective méthodologique** (plan expérimental), mais pas comme prérequis du cœur du projet : il élargit le périmètre (plusieurs labels, gestion des manquants, métriques par antibiotique) alors que l'objectif immédiat est une comparaison contrôlée sur la ciprofloxacine.

A.4 Synthèse

Table 12 – Ce qui est hors périmètre du cœur de la démarche.

Approche	Raison principale d'exclusion
CNN / transformer sur matrice tabulaire	Pas de structure spatiale biologique sur les colonnes
Modèle de fondation	Matrice déjà construite ; coût et complexité injustifiés
Multi-tâches systématique	Élargit le périmètre ; réservé aux perspectives
BSLMM / GEMMA comme modèle principal	Baseline Arcadia utile en perspective, pas au cœur ML/DL

B Reproductibilité : commandes et fichiers

B.1 Fichiers principaux

Table 13 – Fichiers produits et leur rôle.

Fichier	Rôle
`data/processed/ecoli_ciprofloxacin.csv`	jeu de base, préservé
`data/processed/ecoli_ciprofloxacin_snp.parquet`	jeu enrichi ($5\,935 \times 20\,933$)
`data/processed/ecoli_ciprofloxacin_snp.manifest.json`	liste des SNP, positions, effets, porteurs
`data/splits_snp_3way/`	splits train/validation/test groupés par MLST
`src/add_qrdr_snps.py`	extraction et fusion des SNP
`src/make_3way_splits_snp.py`	génération du split groupé
`src/data_loader.py`	chargement des jeux `base`, `snp`, `snp_3way`
`notebooks/exploration_benjamin.ipynb`	expériences et résultats
`slides/presentation.qmd`	présentation Reveal.js

B.2 Commandes

```
python src/add_qrdr_snps.py \
  --vcf data/raw/Ecoli_AMR_GenotypePhenotype/vcf_files/qrdr/qrdr_non_silent.vcf \
  --csv data/processed/ecoli_ciprofloxacin.csv \
  --out-csv data/processed/ecoli_ciprofloxacin_snp.csv \
  --out-parquet data/processed/ecoli_ciprofloxacin_snp.parquet \
  --manifest data/processed/ecoli_ciprofloxacin_snp.manifest.json

python src/make_3way_splits_snp.py
```

B.3 Chargement des données

```
from src.data_loader import load_train, load_validation, load_test

X_train, y_train, meta_train = load_train(dataset="snp_3way")
X_val,   y_val,   meta_val   = load_validation(dataset="snp_3way")
X_test,  y_test,  meta_test  = load_test(dataset="snp_3way")
```

C Glossaire

Ce glossaire regroupe les termes techniques utilisés dans le rapport. Les définitions sont volontairement courtes et orientées vers l'usage qui en est fait dans ce projet.

Table 14 – Glossaire – biologie, génomique et épidémiologie.

Terme	Définition
AMR	*Antimicrobial resistance* : résistance aux antimicrobiens, capacité d'une bactérie à survivre en présence d'un antibiotique qui inhibe ou tue normalement son espèce.
Isolat / souche	Une culture bactérienne issue d'un prélèvement unique. Dans ce projet, chaque ligne du jeu de données correspond à un isolat séquencé.
Pangénome	Ensemble de tous les gènes observés dans une espèce, obtenu en comparant les génomes d'un grand nombre de souches.
Gène *core*	Gène présent chez (presque) toutes les souches d'une espèce. Étant invariant, il est filtré des matrices de présence/absence.
Gène accessoire	Gène présent chez certaines souches seulement. Il varie et peut servir de marqueur de lignage ou de plasmide.
Matrice de présence/absence	Tableau binaire où chaque colonne est un gène ou un cluster pangénomique (1 = présent, 0 = absent).
SNP	*Single Nucleotide Polymorphism* : substitution d'un seul nucléotide à une position donnée du génome.
Variant synonyme	Variant qui ne change pas l'acide aminé codé. Exclu de ce projet car moins directement lié au mécanisme.
Variant non synonyme	Variant qui change la protéine : *missense* (autre acide aminé), *nonsense* (codon stop) ou décalage de cadre. Seuls ceux-ci sont retenus.
QRDR	*Quinolone Resistance-Determining Region* : région des gènes `gyrA`, `gyrB`, `parC` et `parE` où se concentrent les mutations conférant la résistance aux quinolones.
Fluoroquinolone	Classe d'antibiotiques (dont la ciprofloxacine) qui inhibe l'ADN gyrase et la topoisomérase IV, enzymes codées par les gènes QRDR.
CMI (*MIC*)	Concentration minimale inhibitrice : plus faible concentration d'antibiotique inhibant la croissance. C'est la mesure biologique sous-jacente au phénotype binaire.

Terme	Définition (suite)
MLST	*MultiLocus Sequence Typing* : typage par séquençage de 7 gènes de ménage ; la combinaison des allèles définit un *Sequence Type* (ST).
ST (*Sequence Type*)	Identifiant du profil MLST, par exemple `ST131`. Deux isolats de même ST sont généralement des clones.
Lignage / clone	Groupe de souches descendant d'un ancêtre récent, génétiquement très proches.
Déséquilibre de liaison (LD)	Association non aléatoire entre variants proches sur le génome, qui se transmettent ensemble. Conséquence : les variables sont corrélées et les importances se répartissent entre elles.
Phylogénie	Arbre de parenté entre génomes. Le MLST en est un proxy grossier ; une phylogénie fine s'appuie sur les SNP du génome core.
Épistasie	Interaction entre deux mutations : l'effet combiné diffère de la somme des effets individuels.
Résistance plasmidique	Résistance transmise par un plasmide (par exemple les gènes `qnr` ou `aac(6')-Ib-cr`), indépendante des mutations QRDR.
Efflux / porine	Mécanismes non QRDR : pompe qui expulse l'antibiotique, ou perte d'une porine qui limite son entrée.
VCF	*Variant Call Format* : format standard listant les variants détectés par séquençage, avec leurs annotations.

Table 15 – Glossaire – apprentissage automatique et évaluation.

Terme	Définition
Apprentissage supervisé	Apprendre une fonction qui associe des variables d'entrée à une cible observée (ici : génotype → résistant/sensible).
Apprentissage non supervisé	Apprendre une structure sans cible observée ; c'est le cas de l'autoencodeur et de la PCA, qui ne voient jamais y.
Train / validation / test	Trois ensembles disjoints : ajustement des paramètres, choix des hyperparamètres et du seuil, évaluation finale unique.
Fuite de données (*leakage*)	Information du test utilisée indirectement pendant l'entraînement ou la sélection, ce qui gonfle artificiellement les performances.
Split groupé	Découpage où toutes les observations d'un même groupe (ici un MLST) restent dans un seul ensemble, afin d'éviter la fuite de clones.
StratifiedGroupKFold	Validation croisée de scikit-learn qui combine stratification sur y et non-chevauchement des groupes.
Déséquilibre de classes	Situation où une classe est minoritaire (ici 21,65 % de résistants), ce qui rend l'exactitude trompeuse.
Pondération de classe	Donner un poids plus fort à la classe minoritaire dans la fonction de perte, pour augmenter son rappel.

Terme	**Définition (suite)**
Matrice de confusion	Tableau croisant prédictions et vérité : TP, FP, FN, TN. Base de presque toutes les métriques.
Exactitude (accuracy)	Proportion de prédictions correctes. Peu informative en cas de déséquilibre.
Précision	$\mathrm{TP}/(\mathrm{TP}+\mathrm{FP})$: parmi les prédits résistants, combien le sont vraiment.
Rappel / sensibilité	$\mathrm{TP}/(\mathrm{TP}+\mathrm{FN})$: parmi les résistants réels, combien sont détectés. Métrique prioritaire en santé.
Spécificité	$\mathrm{TN}/(\mathrm{TN}+\mathrm{FP})$: parmi les sensibles réels, combien sont correctement classés.
F1	Moyenne harmonique de la précision et du rappel ; pénalise les modèles qui sacrifient l'une pour l'autre.
Balanced accuracy	Moyenne du rappel et de la spécificité ; insensible au déséquilibre.
PR-AUC	Aire sous la courbe précision-rappel. Métrique de référence pour une classe positive minoritaire.
ROC-AUC	Aire sous la courbe ROC (rappel vs taux de faux positifs). Peut paraître optimiste en cas de fort déséquilibre.
Calibration / score de Brier	Qualité des probabilités elles-mêmes, indépendamment du classement. Le score de Brier est l'erreur quadratique moyenne des probabilités.
Seuil de décision τ	Valeur à partir de laquelle une probabilité est convertie en « résistant ». Choisi sur la validation, puis gelé.
Bootstrap	Rééchantillonnage avec remise pour estimer la variabilité d'une métrique et son intervalle de confiance.
Sur-apprentissage	Mémorisation du train sans généralisation ; se traduit par un large écart train/validation.
Régularisation	Ensemble de contraintes qui limitent la complexité : pénalité L2, dropout, arrêt précoce.
Ablation	Retirer ou remplacer un élément (un bloc de variables, une modalité) pour mesurer sa contribution réelle.
Top-k	Sélection des k variables les plus informatives (ici $k = 500$) pour réduire la dimension.
PCA	Analyse en composantes principales : réduction de dimension *linéaire*, servant de référence à l'autoencodeur.
Autoencodeur	Réseau non supervisé entraîné à reconstruire son entrée via une couche latente compressée ; la couche latente sert ensuite de représentation.
Embedding / espace latent	Vecteur de dimension réduite produit par un modèle (autoencodeur), sans signification individuelle directe pour ses composantes.
MLP	*Multi-Layer Perceptron* : réseau de neurones entièrement connecté, approximateur universel de fonctions.
SHAP	Méthode d'attribution qui répartit la prédiction d'un individu entre les variables, avec une base théorique issue des jeux coopératifs.

Terme	Définition (suite)
TreeSHAP	Version exacte et rapide de SHAP pour les modèles d'arbres (forêt aléatoire, XGBoost).
LIME	Explication locale approchée par un modèle linéaire ajusté autour d'un individu ; agnostique au modèle mais moins stable.
Importance par permutation	Chute de performance observée lorsqu'on mélange aléatoirement une variable ; mesure agnostique au modèle.
Baseline	Modèle de référence simple (ici LogReg, ou « tout sensible ») auquel comparer les modèles plus complexes.
BSLMM	*Bayesian Sparse Linear Mixed Model* : modèle de génétique quantitative utilisé par Patton et al. (2025), qui estime des effets de marqueurs et l'héritabilité.
Héritabilité	Part de la variance phénotypique attribuable à la variation génétique dans une population donnée.

D Notations

Table 16 – Notations utilisées dans le rapport.

Notation	Signification
N	nombre d'isolats
P	nombre de variables
y_i	phénotype binaire de l'isolat i
$\hat{p}_i$	probabilité prédite d'être résistant
τ	seuil de décision
TP, FP, FN, TN	vrais positifs, faux positifs, faux négatifs, vrais négatifs
PR-AUC	aire sous la courbe précision-rappel
ROC-AUC	aire sous la courbe ROC
w_+	poids de la classe résistante
λ	coefficient de régularisation